



UNIVERSITÀ DEGLI STUDI DI MILANO
FACOLTÀ DI SCIENZE E TECNOLOGIE

Corso di Laurea in Sicurezza dei Sistemi e delle Reti Informatiche

Recupero e implementazione di
componenti ML per analisi dati in un
contesto distribuito

Relatore

Prof. Claudio A. Ardagna

Correlatori

Prof. Marco Anisetti

Dott. Antongiaco Polimeno

Tesi di laurea di

Gabriele Stentella

984491

Anno Accademico 2023/2024

Prefazione

Fra il 2003 e il 2008, Google divulgò tre componenti fondamentali sviluppati per affrontare la sfida di indicizzare internet: la tecnologia del proprio file system [14], il modello MapReduce [9] e il sistema di archiviazione dati distribuito Bigtable [4]; rivoluzionando l'industria nascente dei *Big Data* e gettando le basi per lo sviluppo del framework *Hadoop*, uno strumento *open source* che ha consentito una larga adozione di tecniche per la computazione distribuita. Negli anni successivi, molte di quelle che ora sono le grandi aziende tecnologiche statunitensi hanno cominciato ad utilizzare *Hadoop* e sviluppato un ecosistema con tale tecnologia al centro, composto da diversi file system distribuiti e framework per convertire le classiche interrogazioni *SQL* in lavori MapReduce. Dal momento che avviare e gestire un cluster *Hadoop* era un'operazione costosa e impegnativa, la vera adozione di massa dell'infrastruttura è avvenuta quando Amazon lanciò il suo servizio di cloud computing *on-demand* e contestualmente *Elastic MapReduce (EMR)*, consentendo di sfruttare i vantaggi del modello MapReduce impiegando il file system distribuito *Amazon S3* senza dover acquistare e configurare l'hardware necessario.

Nel 2010 Google rilasciò una nuova ricerca [20] in cui veniva illustrata un'architettura per *query* distribuite e un formato di archiviazione utile a rendere efficienti le operazioni, ancora una volta ispirando altre aziende a sviluppare e poi rendere *open source* tecnologie come *Apache Impala*, *Presto* e *Apache Parquet*.

Alcuni anni dopo vennero rilasciate le prime versioni di *Apache Spark* che ottennero da subito un grande successo, infatti era molto semplice migrare da sistemi per interrogazioni *SQL* di *Hadoop* a *SparkSQL*, e il nuovo framework aveva una sintassi più semplice e migliori performance di MapReduce, grazie alla sua capacità di utilizzare la RAM come cache. La gestione delle risorse del cluster era gestita attraverso il *resource manager Hadoop Yarn*. Poco dopo *Spark* cominciò ad avere successo anche nel mondo del Machine Learning (ML), grazie al framework *Apache Mahout* prima, e poi alla *Machine Learning library (MLlib)*, più veloce; inoltre le possibilità offerte da *Spark* si ampliarono grazie alla nascita di scheduler come *Apache Airflow* e *Luigi*.

Fra il 2013 e il 2014 si diffusero *Docker* e l'orchestratore *Kubernetes* che sem-

plificarono la gestione di cluster anche di grandi dimensioni, rendendo le architetture molto spiù stabili e scalabili; *Spark* si è adattato al contesto, permettendo di utilizzare proprio *Kubernetes* come *resource manager*.

Con l'avvento del Deep Learning (DL) le attività di computazione si sono spostate sull'utilizzo massiccio di GPU e sull'impiego delle più importanti librerie di *Python* dedicate, *Tensorflow* e *Pytorch*, dunque per questi carichi di lavoro si è passati all'utilizzo delle Application Programming Interface (API) proprietarie delle librerie per distribuire la computazione anziché usare *Spark*, in modo da usare in maniera efficiente la GPU ed evitare di dover creare un cluster per poi installare le librerie su tutti i componenti.

Il percorso che si intende illustrare in questo elaborato ha previsto sia una fase di recupero di algoritmi ML pre-esistenti per la loro esecuzione in un ambiente distribuito attraverso *Spark*, sia l'implementazione di nuovi algoritmi che sfruttano le API delle moderne librerie per lo sviluppo di algoritmi di DL. Nell'introduzione viene analizzato lo scenario di partenza che rappresenta il contesto in cui si inserisce il lavoro di tesi, in modo tale da illustrare nel dettaglio le motivazioni alla base dell'attività svolta, per poi descrivere il contributo dato dalla soluzione proposta e dettagliare la struttura della trattazione che segue.

Indice

1	Le tecnologie per l'analisi dati e il calcolo distribuito	4
1	L'IA per l'analisi dati	4
1.1	Tensorflow	5
2	Apache Spark	6
3	Docker	9
4	Kubernetes	9
2	Gli algoritmi di analisi dati	10
3	Recupero degli algoritmi	16
1	Analisi	16
2	Esecuzione su un cluster Kubernetes locale	19
3	Esecuzione su un cluster AWS EKS	21
4	Studio e implementazione di un algoritmo di test in Tensorflow	23
1	Analisi	23
2	Configurazione dell'ambiente di lavoro	24
3	Implementazione	25
5	Deployment sull'infrastruttura distribuita finale	28
1	Architettura MUSA	28
2	Processo di deployment	28
6	Testing e valutazione delle performance in ambiente distribuito	29
1	Spark task	29
2	Tensorflow task	30
7	Conclusioni	32
A	POM generale	33
B	POM di un singolo modulo	34

C Identity and Access Management (IAM) policies	37
D Configurazione di EKS StartJobRun	40
E Estratto dai log di un esecuzione su cluster EKS	42
Bibliografia	49

Elenco delle figure

3.1	Funzionamento di spark-submit	20
3.2	Schema riassuntivo dell'infrastruttura configurata con Amazon EKS	22

Introduzione

La presenza sempre più diffusa dei *Big Data* ha reso necessario avere infrastrutture e tecnologie di analisi adatte ad estrarre valore da tali dati e che siano scalabili per essere utilizzate da realtà di diverse dimensioni. Al fine di avere procedure efficaci sia nell'attività di analisi che in quella di costruzione di modelli predittivi, occorre affrontare i problemi tipici dei *Big Data* che sono la diffusa eterogeneità, l'accumulo di rumore in fase di raccolta, la frequente presenza di correlazioni spurie. Gli algoritmi impiegati devono essere anche accurati dal punto di vista statistico ed efficaci per quanto riguarda il carico computazionale; per tutte queste ragioni, ma in modo particolare per la necessità di efficienza computazionale, i *Big Data* hanno portato allo sviluppo di nuove infrastrutture di computazione e nuovi metodi di memorizzazione dei dati [13].

In tale contesto, le tecnologie di *Apache Hadoop* prima e *Apache Spark* poi, hanno reso semplice ed economica l'analisi e la memorizzazione dei dataset di grandi dimensioni, in particolare, dal momento che l'analisi di *Big Data* richiede una sperimentazione reiterata per trovare i parametri corretti e individuare le giuste metriche di valutazione, *Spark* rappresenta una soluzione tecnologicamente adatta a supportare in modo efficiente questo tipo di lavoro, in particolare se viene utilizzata la libreria MLlib per il *design* e il *tuning* di algoritmi ML [24].

Negli ultimi anni, oltre agli algoritmi ML di *shallow learning*, hanno avuto molto successo i modelli DL che, a differenza delle architetture *shallow*, traggono vantaggio dall'avere un grande numero di parametri liberi, quindi l'addestramento di tali modelli vede nei *Big Data* una risorsa fondamentale, e contemporaneamente necessita di metodi efficienti per la parallelizzazione delle operazioni di *training* [33].

I benefici dati da un'analisi dati svolta con l'ausilio di algoritmi ML o modelli DL sono evidenti nel campo della ricerca medica e scientifica, nella gestione di infrastrutture critiche e nella cosiddetta *business intelligence* [17], ma la letteratura è sempre più ricca di applicazioni di queste tecnologie nel campo della sicurezza informatica: grazie alla presenza pervasiva dell'Internet of Things

(IoT) e in generale dell'evoluzione tecnologica dei dispositivi informatici, compresi gli strumenti di rete, c'è una grandissima produzione di dati che possono essere analizzati in tempo reale per eseguire azioni di prevenzione, ricerca di minacce e *incident response*. Soltanto alcune fra le numerose applicazioni in questo campo sono l'analisi del traffico di rete con l'obiettivo di istituire uno schema di priorità e rendere meno efficaci eventuali attacchi Denial of Service (DoS), identificare comportamenti sospetti, individuare malware e integrare i sistemi di autenticazione [25]. In particolare, l'uso dei classificatori è utile per implementare dei filtri sia sul traffico web sia sulla corrispondenza di posta elettronica, in modo tale da ridurre la probabilità che il personale di un'azienda entri in contatto con contenuti malevoli, e di conseguenza minimizzare l'impatto di email spam o siti web malevoli sulla rete aziendale o di un'infrastruttura critica; i classificatori in questione devono essere allenati con un insieme di dati molto grande e in continuo aggiornamento, in modo tale che stiano al passo con l'evoluzione delle minacce, inoltre è necessario che, in base al tipo di classificazione, venga utilizzato un modello statistico adeguato.

L'obiettivo del lavoro svolto durante il tirocinio interno, è quello di recuperare degli algoritmi ML di analisi dati che sono stati sviluppati in linguaggio Java e utilizzano la tecnologia *Spark*, con il fine di renderli eseguibili in un ambiente distribuito, superando il *resource manager* originario Hadoop Yarn e utilizzando Kubernetes. Parallelamente al recupero degli algoritmi esistenti, la tesi si pone l'obiettivo di studiare la tecnologia di esecuzione distribuita della libreria *Tensorflow* per lo sviluppo di nuovi algoritmi per l'analisi dati eseguibili nel medesimo ambiente distribuito dei precedenti. L'infrastruttura finale — pensata per lo storage sicuro e l'elaborazione di *Big Data* — in cui si sono eseguiti gli algoritmi, è un ambiente distribuito amministrato con l'orchestratore Kubernetes ed è stata implementata nell'ambito del progetto Multilayered Urban Sustainability Action (MUSA) finanziato dal Ministero dell'Università e della Ricerca attraverso il Piano Nazionale di Ripresa e Resilienza.

Il principale contributo di questo elaborato è lo studio della possibilità di distribuire la computazione di algoritmi già implementati, con modifiche minime o del tutto assenti alla logica dell'applicazione. Nel momento in cui il codice e l'infrastruttura di esecuzione sono disaccoppiati, infatti, il riuso di programmi già esistenti diventa molto più agevole e consente di utilizzare algoritmi come quelli coinvolti in questa tesi come componenti per sistemi più complessi. Per aggiungere un ulteriore elemento di disaccoppiamento fra codice ed infrastruttura, il lavoro si è concentrato anche sulla possibilità di eseguire in un unico ambiente — nel caso di specie gestito con Kubernetes — applicazioni che sfruttano tecnologie e linguaggi differenti.

L'elaborato è organizzato come segue: nel capitolo 1 si espone lo stato dell'arte delle tecnologie per l'analisi dati e il calcolo distribuito, in modo tale

da introdurre gli aspetti tecnici alla base del lavoro svolto; nel capitolo 2 si illustrano gli algoritmi coinvolti nella tesi; nel capitolo 3 viene descritto nel dettaglio il lavoro svolto per il recupero di algoritmi pre-esistenti; il capitolo 4 analizza nel dettaglio la fase dedicata allo studio dell'implementazione di nuovi algoritmi; con il capitolo 5 viene affrontato il deployment sull'architettura sviluppata all'interno del progetto MUSA; il processo di testing e di relativa valutazione delle performance degli algoritmi in contesto distribuito è riportato nel capitolo 6; nel capitolo 7 si riassume il contributo dato da questa tesi e si esplorano i possibili sviluppi futuri.

Capitolo 1

Le tecnologie per l'analisi dati e il calcolo distribuito

1 L'IA per l'analisi dati

Con le tecniche di analisi statistica convenzionali si ricerca un modello che descriva in modo appropriato i dati che si hanno a disposizione o, più frequentemente, le variabili del dataset ritenute significative. Attraverso approcci di Intelligenza Artificiale (IA), che siano modelli predittivi o strumenti di data mining, si evita di legarsi ad un modello definito a priori, ma si utilizzano i dati nella loro completezza per costruire un modello e individuare dei pattern comuni, segue che al crescere della qualità dei dati in ingresso e della loro varietà, l'accuratezza dell'analisi aumenta.

Gli algoritmi sono suddivisibili in due categorie sulla base del funzionamento in fase di apprendimento:

1. nel *supervised learning* i dati sono etichettati, quindi si hanno n esempi, ciascuno composto dal dato (x) e dalla relativa etichetta (y), l'obiettivo di un algoritmo di apprendimento in questa categoria, è quello di trovare una funzione che associ ad ogni x la relativa y . Spesso la funzione in questione non serve per trovare con certezza matematica una certa y , ma restituisce il valore che ha probabilità maggiore di essere l'etichetta per un dato x ;
2. per lavorare con dati senza etichette associate si utilizzano algoritmi di *unsupervised learning* che cercano di costruire una rete con il comportamento desiderato in maniera iterativa, adattando i pesi interni al modello per avvicinarsi di volta in volta all'obiettivo.

Come appare evidente dal funzionamento delle diverse modalità di apprendimento, l'obiettivo dei principali algoritmi di *supervised learning* è quello di fare predizioni osservando nuovi dati, sulla base di modelli costruiti su una collezione di dati dedicati, mentre quello dei principali algoritmi di *unsupervised learning* è ottenere informazione utile estraendo le caratteristiche più interessanti (pattern, anomalie o trend particolari) da dataset di grandi dimensioni. Gli algoritmi predittivi possono essere utilizzati sia per assegnare i dati a specifiche categorie predeterminate (classification), ovvero fare previsioni con un output discreto, sia per identificare le relazioni presenti fra le diverse variabili (regression), ovvero effettuare previsioni con output continuo. L'individuazione dei pattern comuni all'interno di grandi collezioni di dati, invece, può essere sfruttata per molteplici obiettivi diversi: oltre alla costruzione di modelli si possono svolgere attività di preparazione dei dati oppure utili per analisi descrittive, per esempio, lavorando con *Big Data* può essere utile dividere il dataset in gruppi di oggetti con caratteristiche comuni (*cluster analysis*), inoltre, dal momento che gli insiemi di dati hanno frequentemente un'elevata dimensionalità, sono spesso necessarie azioni che mirano alla riduzione dello spazio delle caratteristiche dei dati in questione, pur mantenendo le informazioni significative.

A tal proposito, è bene evidenziare che fra gli algoritmi che verranno illustrati in seguito, K-means clustering, Gaussian Mixture Models, Principal component analysis, sono algoritmi di apprendimento non supervisionato, mentre metodi come Linear regression, Logistic regression, K-nearest neighbor, Support vector machines e Random forest sono riconducibili ad apprendimento supervisionato.

1.1 Tensorflow

La libreria open-source Tensorflow, rilasciata nel 2015, è dedicata alla costruzione di reti neurali e ha ricoperto un ruolo importante nell'evoluzione del settore. Ad oggi è la libreria che, insieme a Pytorch [paszke:2019], è diventata lo standard *de facto* per lo sviluppo di modelli ML ed in particolare DL. Attraverso un unico grafico di flusso (*dataflow graph*) viene rappresentata l'intera computazione di un modello, infatti sono compresi tutti i calcoli, gli stati, i parametri, le regole di aggiornamento degli stessi e le modalità di pre-processing dei dati. I componenti del grafico sono: *Tensors*, ovvero array con n dimensioni; *Operations* che sono azioni di trasformazione sui Tensors; *Variables*, operazioni con un buffer variabile; diverse implementazioni di *Queues* composte da Tensors [abadi:2016]. Con le API è possibile gestire lo sviluppo del modello, il monitoraggio delle performance e il debugging, oltre alla fase di "serving" in cui si fornisce un modello allenato pronto all'uso da parte di terzi. Fra i vantaggi offerti da Tensorflow ci sono la possibilità di creare modelli complessi,

combinando algoritmi già esistenti e offerti direttamente dalla libreria, oltre alla semplicità con cui si può ottimizzare il codice per l'esecuzione su hardware specifico. Un altro aspetto fondamentale è quello di poter sfruttare l'efficienza delle API offerte per lo streaming dei dati in pipeline di modelli DL.

Il modulo Keras offre API di alto livello che offrono le componenti necessarie a costruire reti neurali complesse. Le tre API principali sono:

- Sequential, per la costruzione di reti semplici, ovvero con un singolo input, un unico flusso attraverso gli hidden layers e un output.
- Functional consente di formare reti più complesse, con molteplici input, hidden layers paralleli e più di un output.
- Con Sub-classing è possibile personalizzare ogni singolo layer della rete, dunque si può fare in modo che ognuno sia un sotto-modello del modello finale.

All'interno di `tf.keras.layers` si trovano i layer già implementati, i quali consistono in una funzione di computazione che opera con Tensors, e alcune variabili che rappresentano i pesi del singolo componente. Grazie a tali variabili, un layer mantiene il proprio stato, dunque ogni volta che la funzione al suo interno viene chiamata il punto di partenza della computazione dipende dal risultato del ciclo precedente. L'API in questione consente una gestione dettagliata di ciascun layer, permettendo di impostare la tipologia, la forma dell'input e dell'output, la funzione di attivazione, il numero di nodi che lo compongono. Qualora si realizzi una rete con Sub-classing, si definiscono uno o più layer personalizzati, estendendo la classe Layer e ridefinendo le funzioni `__init__()`, `build()` e `call()`. La prima serve per l'inizializzazione del layer, la seconda per la creazione dei parametri del modello, la terza è la computazione da svolgere con i Tensors che il layer riceve in input.

Una volta che si è definito il codice per l'addestramento del modello, attraverso Tensorboard si può monitorare il processo di training, in questo modo è possibile individuare eventuali anomalie. Inoltre, il servizio permette di visualizzare i dati e verificare le performance del modello. Il monitoraggio è fondamentale soprattutto per impedire overfitting o underfitting.

2 Apache Spark

Spark è una tecnologia open-source per l'elaborazione dei dati su cluster di computer, supporta una varietà di linguaggi di programmazione comuni e include librerie per molti compiti diversi. Il suo scopo è rendere semplice l'elaborazione di *Big Data*.

Architettura L'architettura di Spark si basa su due astrazioni principali: Resilient Distributed Datasets (RDD), per l'archiviazione dei dati, e Directed Acyclic Graph (DAG), per l'elaborazione dei dati. Con "Resilient Distributed Datasets" si indicano le unità fondamentali con cui vengono gestiti i dati, sono collezioni di elementi che possono essere distribuiti tra nodi in un cluster e su cui è possibile lavorare in parallelo. In caso di un guasto, con gli RDD è possibile ricalcolare i dati: agiscono come un'interfaccia verso i dati. Una volta che i dati sono caricati in un RDD, Spark esegue trasformazioni e azioni sugli RDD in memoria (Spark memorizza anche i dati in memoria a meno che il sistema non la esaurisca o l'utente decida di scrivere i dati su disco per la persistenza) e distribuisce automaticamente le operazioni. Ogni trasformazione è un insieme di operazioni applicate per creare un nuovo RDD. Ogni volta che un nodo Spark riceve come compito lo svolgimento di operazioni, il suo ruolo è quello di applicare il calcolo agli RDD e restituire il risultato al driver. "Directed Acyclic Graph" è l'espressione con cui si indica il livello di pianificazione dei lavori in Spark, implementa un modello di esecuzione *stage-oriented* e quindi elimina il modello di esecuzione Hadoop MapReduce. Per esecuzione *stage-oriented* si intende che ogni lavoro eseguito da Spark viene diviso in insiemi più piccoli di calcoli (detti appunto *stage*) e vengono eseguiti singolarmente, anche se dipendono l'uno dall'altro. In sintesi, DAG coordina i nodi worker nel cluster e rende possibile la risoluzione degli errori. I tipi di dati con cui lavora Spark sono DataFrames e DataSets. I DataFrames sono degli strumenti per contenere dati e offrono delle API per la distribuzione su più nodi. Sono simili a una tabella di un database relazionale o a un file csv con intestazione: i dati sono organizzati in righe e colonne (anche di tipi eterogenei) e l'elaborazione viene eseguita attraverso funzioni definite dall'utente e altre funzioni di manipolazione (group, join, sort), sono un'astrazione implementata nel modulo Spark SQL. I DataSets sono una collezione di oggetti JVM fortemente tipizzati, quindi sono un'interfaccia di programmazione orientata agli oggetti sicura dal punto di vista del tipo, a differenza dei DataFrames che forniscono uniformità tra più linguaggi.

Componenti L'architettura è composta da quattro componenti: il driver, gli esecutori, il cluster manager e i nodi worker. Lo Spark driver è il nodo principale che controlla il cluster manager, il quale a sua volta gestisce i nodi worker (anche detti slave) e fornisce i risultati dei dati al client dell'applicazione. Quando viene eseguito, il driver chiama l'applicazione reale e costruisce lo SparkContext che contiene tutte le funzioni di base per il funzionamento dell'applicazione. Il driver e il cluster manager controllano l'esecuzione dei nodi worker: il cluster manager assegna le risorse per i lavori da svolgere, quindi una volta che il lavoro è stato suddiviso in componenti più piccoli e distribuito

ai nodi worker, il driver controlla l'esecuzione. Molte tipologie di worker elaborano un RDD creato nel contesto Spark, quindi i risultati di ciascun nodo possono essere memorizzati nella cache [21]. In sintesi:

- il cluster manager assegna le risorse necessarie per l'elaborazione dei dati, ci sono diversi gestori fra cui YARN, Mesos e Kubernetes;
- il driver crea lo `SparkContext` nell'applicazione. Non appena il lavoro Spark viene avviato, esegue il metodo `main()` dell'applicazione e crea il DAG che rappresenta il flusso interno dei dati. In base ad esso, il driver richiede al cluster manager di allocare le risorse (nodi worker) necessarie per l'elaborazione. Una volta allocate le risorse, il driver utilizza lo `SparkContext` per inviare il codice unito ai dati verso i nodi worker per eseguirlo come Task, e ne riceve il risultato;
- un nodo worker è un componente del cluster che gestisce le risorse e ospita gli esecutori. È responsabile del coordinamento e della supervisione dell'esecuzione dei compiti su quel particolare nodo, comunica con il cluster manager per ottenere le risorse e ne segnala l'utilizzo. Implementa l'ambiente di esecuzione per gli esecutori, gestendo il loro ciclo di vita sul nodo;
- un esecutore è un processo in esecuzione su un nodo worker in un cluster. Esegue i compiti assegnati dal driver Spark ed è responsabile per l'esecuzione della sua unità di lavoro. Per impostazione predefinita, Spark crea un esecutore per ogni nodo nel cluster, ma è possibile configurarne il numero in base alle esigenze dell'applicazione. Ci sono quattro tipi di esecutori: default, per compiti di elaborazione dati generici; coarse-grained, per compiti che richiedono più memoria; fine-grained, per compiti che richiedono meno memoria; external executors, utilizzati quando l'applicazione deve usare risorse esterne per l'elaborazione (ad esempio una GPU per l'elaborazione).

Esecuzione La classe `SparkSession` permette di accedere a tutte le funzionalità di Spark: incapsula `SparkConf` e `SparkContext`, è creata con il builder design pattern e una volta istanziata è possibile configurare le proprietà dell'ambiente di esecuzione di Spark. A tal proposito, si distinguono tre diversi modi di esecuzione:

1. Local è l'impostazione ideale per il testing, consiste nell'eseguire Spark su una singola macchina, tutta l'elaborazione è eseguita da un singolo processore.

2. Con cluster un jar precompilato (o uno script python/R) viene consegnato a un cluster manager, poi il driver viene avviato su un nodo worker all'interno del cluster, oltre ai processi degli esecutori.
3. Utilizzando client il programma driver viene eseguito sulla macchina client, mentre gli esecutori vengono eseguiti sul cluster.

MLlib La libreria Spark MLlib serve per il training e il tuning di diversi algoritmi ML, in maniera distribuita e con interfacce indipendenti dall'algoritmo sottostante. Implementa le astrazioni di *estimators*, *transformers* e *evaluators* e offre, attraverso opportune API, numerosi algoritmi ML. I dati sono gestiti attraverso gli oggetti DataFrame. I transformers sono impiegati per modificare i dataset aggiungendo previsioni, dunque i modelli ML in MLlib sono a tutti gli effetti transformers. Gli estimators generano transformers adattandoli ai dati, attraverso il metodo `fit()` si usano gli estimators per allenare un modello su un dataset. Gli evaluators analizzano le prestazioni del modello utilizzando. La libreria offre anche la possibilità di unire transformers ed estimators a formare oggetti di tipo PipelineStages, in modo tale da definire una sequenza ordinata di operazioni da svolgere (Pipeline) al fine di realizzare un flusso di lavoro completo che porta dai dati grezzi al modello ML finale. Ogni componente della sequenza riceve in ingresso un DataFrame e ne produce uno in output, chiamando il metodo `fit()` sull'oggetto Pipeline si avvia l'esecuzione di tutti i passaggi [34].

3 Docker

4 Kubernetes

Capitolo 2

Gli algoritmi di analisi dati

Una parte fondamentale del lavoro svolto è stata quella di recuperare degli algoritmi ML e statistici sviluppati in linguaggio Java, sfruttando le librerie offerte da Spark. Di seguito si descrivono in dettaglio le tecniche di inferenza e gli algoritmi implementati dai task.

K-means clustering K-means è un algoritmo di clustering con approccio partizionale, ottiene in input il parametro k , numero di cluster, poi la computazione inizia selezionando k centroidi casuali dal dataset su cui è eseguito, viene calcolata la distanza fra ogni punto del dataset e i centroidi, in modo da assegnare ogni dato al cluster relativo al centroide più vicino. Ogni volta che un nuovo punto viene assegnato al cluster, il centro viene ricalcolato, quindi l'algoritmo viene eseguito iterativamente finché i cluster non sono stabili (nessun punto viene più assegnato a un nuovo cluster) [16]. Osservando il clustering come un *learning problem* — ovvero trattandolo come un compito di apprendimento automatico in cui l'obiettivo è assegnare automaticamente gli oggetti in gruppi omogenei — si utilizza l'algoritmo K-means per allenare un modello ML che possa essere sfruttato per poi svolgere delle predizioni: fornito un nuovo punto che rappresenta un dato non presente nel dataset con cui si è svolto il *training*, il modello deve essere in grado di collocarlo in uno dei cluster che ha individuato. Fra i task implementati, uno è dedicato alla creazione del modello e uno all'utilizzo di tale modello per svolgere le predizioni; è inoltre presente un task dedicato alla valutazione del modello, sfruttando il *Silhouette score* [28]. Nella versione classica dell'algoritmo la metrica utilizzata è la distanza euclidea, ma sono state proposte diverse alternative al fine di migliorare le performance [6, 5, 29]. La variante bisecting K-means [31] sfrutta l'algoritmo di base per implementare una procedura differente: inizialmente il dataset è considerato come un unico cluster e viene utilizzato K-means per dividerlo in due cluster, si ripete il processo un certo numero di volte e poi si tiene la sezione che presenta due

cluster con la più alta similarità fra gli elementi, infine vengono iterati i passaggi precedenti fino a raggiungere il numero di cluster desiderato. Come nel caso dell'algoritmo di base, anche bisecting K-means viene utilizzato per creare un modello con cui poi effettuare delle predizioni.

Decision Tree Classifier I classificatori ad albero sono modelli predittivi con una struttura assimilabile a un diagramma di flusso, ideali per il data mining supervisionato. Ogni nodo dell'albero è un test su un attributo del dato da classificare, ogni ramo è un possibile esito del test e ogni foglia indica l'etichetta di classificazione. Il nodo radice non ha rami in ingresso ed è infatti il punto di ingresso all'albero stesso. La classificazione viene effettuata eseguendo i test rappresentati dai nodi, di volta in volta scegliendo il test successivo sulla base del risultato del precedente, continuando fino all'ultimo livello (terminale), in cui tutte le tuple di dati in un nodo comprendono campioni di una sola classe. La costruzione del modello avviene seguendo la fase di generazione (*generation*) prima e di potatura (*pruning*) poi; nella prima fase tutte i dati di allenamento partono nel nodo radice, viene definito un criterio di divisione ed è selezionato il miglior attributo per effettuare la divisione, dopodiché i dati vengono partizionati nei nodi figli e la procedura è ripetuta fino a quando aggiungendo nodi foglia non si aumenta più la precisione dei nodi foglia. Nella seconda fase si punta a ridurre le dimensioni del modello in modo da renderlo più efficiente, in particolare vengono rimossi i sottoalberi che si sono creati per riflettere le caratteristiche di eventuale rumore nei dati o outliers [22]. Una volta che si ha un modello affidabile ed efficiente, lo si può utilizzare per la classificazione di dati.

Gaussian Mixture Model Si tratta di un modello statistico utilizzato per rappresentare la distribuzione di probabilità di un insieme di dati come una combinazione di più distribuzioni gaussiane. Un Gaussian Mixture Model (GMM) assume che i dati siano generati da un insieme di sottopopolazioni, ognuna che segue una distribuzione gaussiana. È definito da un numero specifico di componenti gaussiane, ognuna con la propria media e varianza; l'obiettivo dell'algoritmo è quello di costruire un modello sulla base di un certo insieme di dati, in modo tale da eseguire poi predizioni collocando nuovi dati nella gaussiana corretta (ovvero stimando la variabile latente) [23]. Il modello viene costruito utilizzando la classe offerta da Spark GaussianMixtureModel in un task, poi un secondo utilizza il modello per eseguire le predizioni.

K-Nearest Neighbors Classifier L'algoritmo k-nearest neighbors [8] è stato utilizzato per costruire un classificatore, quindi il task che lo implementa ha

l'obiettivo di restituire in output la classe a cui appartiene un oggetto che riceve in input. La classificazione avviene scegliendo la classe più comune fra i k oggetti con features più simili (e quindi "vicini") all'oggetto da classificare, dove k è parametro dell'algoritmo. Dal momento che il funzionamento dell'algoritmo si basa sul confronto della distanza fra l'oggetto da classificare e una serie di oggetti conosciuti, la fase di allenamento del modello consiste nell'estrazione delle caratteristiche dai dati dedicati al training, in modo da rappresentare ogni oggetto come un vettore in uno spazio n -dimensionale (dove n è il numero delle caratteristiche). Ogni vettore è in seguito assegnato a una classe sulla base della classificazione indicata nel dataset, si tratta dunque di un metodo di apprendimento supervisionato e non parametrico [30]: non vengono fatte assunzioni sulla distribuzione dei dati su cui opera l'algoritmo, rendendolo adatto alla classificazione di dati di cui non si conosce la distribuzione; occorre tenere presente, tuttavia, che il meccanismo con cui avviene la classificazione, comprende intrinsecamente il rischio che la classificazione sia svolta con bassa accuratezza nel caso in cui la distribuzione sia fortemente asimmetrica, perché gli esempi di una classe più frequente tendono a dominare la previsione di un nuovo esempio (tendono ad essere comuni tra i k vicini più prossimi a causa del loro grande numero), per questo sono state proposte delle alternative alla regola di base del voto a maggioranza dei k vicini [7]. Utilizzando le classi di Spark dedicate al modello KNNC — `KNNClassificationModel` e `KNNClassifier` — viene costruito il classificatore sulla base di un dataset in input, per poi utilizzare il modello per effettuare le predizioni.

Linear Discriminant Analysis Si tratta un algoritmo di riduzione della dimensionalità e di classificazione utilizzato nell'ambito dell'apprendimento supervisionato. L'obiettivo è trovare la combinazione lineare delle caratteristiche che massimizza la separazione tra le classi dei dati utilizzati nell'allenamento del modello, per farlo l'algoritmo LDA proietta i dati in uno spazio delle caratteristiche a dimensioni inferiori, senza perdere informazioni, in modo che le diverse classi siano il più separabili possibile lungo questa nuova dimensione. Vengono calcolate le medie delle caratteristiche per ciascuna classe, oltre alle matrici di dispersione intra-classe (*data spread* all'interno di una classe) e inter-classe (*data spread* fra le classi). Successivamente si calcolano le direzioni discriminanti, ovvero i vettori che massimizzano il rapporto tra la varianza inter-classe e la varianza intra-classe, i dati vengono proiettati su queste direzioni per ridurre la dimensionalità e separare le classi nel nuovo spazio delle caratteristiche. Dopo la proiezione dei dati, è possibile utilizzare un classificatore per classificare i nuovi dati in base alla loro posizione nello spazio delle caratteristiche ridotto. LDA è spesso utilizzato come tecnica di riduzione della

dimensionalità prima di applicare un classificatore, poiché aiuta a migliorare le prestazioni del modello riducendo il rischio di overfitting. È da notare che vengono fatte le assunzioni che i dati siano distribuiti normalmente e che le classi abbiano matrici simili [32]. Nel task implementato, vengono utilizzate le classi di clustering offerte da Spark LDA e LDAModel per allenare il modello ed effettuare le predizioni.

Principal Component Analysis In modo simile a LDA, questo algoritmo mira a ridurre la dimensionalità dei dati ed è quindi utilizzato nel *preprocessing*; l'idea di base è quella di estrarre le informazioni importanti dal dataset, per poi rappresentarle come variabili ortogonali (le componenti principali) ottenute come combinazioni lineari delle variabili originali, in modo tale da poter poi distinguere graficamente i diversi cluster. Per estrarre la prima componente si ricerca quella che ha varianza maggiore, perché in questo modo si estrae la maggior quantità di informazione dal dataset, per la seconda si pone il vincolo di ortogonalità con la prima e si cerca nuovamente quella con varianza maggiore (tolta la prima), reiterando il processo un numero pari alle componenti che si desidera estrarre [1]. Più nel dettaglio, il processo consiste in una prima normalizzazione dei dati (sottraendo la media e dividendo per la deviazione standard), per poi calcolare la matrice di covarianza (σ) dei dati, in seguito si calcolano autovalori e autovettori di σ , vengono selezionate le componenti principali estraendo gli autovettori con i corrispondenti autovalori più grandi, infine si proiettano i dati normalizzati sulle componenti principali estratte per ridurre la dimensionalità. Grazie alle classi di Spark PCA e PCAModel, il task esegue il *fitting* del modello e poi restituisce un dataset con le informazioni relative alle componenti principali.

ANalysis Of VAriance (ANOVA) ANOVA è una tecnica di inferenza statistica utilizzata per analizzare la differenza fra le medie di più gruppi differenti di dati, con il fine di descrivere le relazioni presenti fra le variabili presenti nel dataset. È particolarmente utile per analizzare i dati ottenuti da diverse misurazioni svolte in seguito a diversi generici "trattamenti" eseguiti nel corso di un esperimento, perché consente di valutare la significanza statistica dei "trattamenti" confrontando i dati con quelli di un ipotetico gruppo di controllo. Per utilizzare ANOVA si assume che ogni gruppo su cui si sono effettuate le misurazioni segua una distribuzione normale, le varianze delle popolazioni di provenienza dei gruppi siano uguali fra loro, le osservazioni sui vari gruppi siano indipendenti; l'ipotesi nulla è che tutte le medie delle diverse popolazioni considerate siano uguali, quindi che non ci sia una differenza significativa fra i diversi gruppi, mentre l'ipotesi alternativa è che almeno una media sia diffe-

rente, con un certo livello di significanza. La versione più semplice dell'analisi è *one-way ANOVA*, in cui viene esaminata l'influenza di una singola variabile indipendente, ed è quella eseguita dal task nel caso in cui il dataset in input sia composto da sole due colonne (una per la variabile dipendente e una per quella indipendente); la versione *two-way ANOVA*, che analizza l'influenza di due differenti variabili indipendenti, è eseguita se il dataset ha tre colonne, la versione *multi-way ANOVA* serve per l'analisi della varianza provocata da più di due variabili indipendenti simultaneamente ed è eseguita se il dataset ha almeno quattro colonne. L'algoritmo restituisce una tabella contenente i gradi di libertà, la somma dei quadrati, la media dei quadrati, l'*f-ratio*, il *p-value*, il numero di celle del dataset, la somma e la media dei loro valori. L'*f-ratio* è il rapporto fra la varianza tra i diversi gruppi, e la varianza all'interno dei singoli gruppi, mentre il *p-value* è la probabilità che l'*f-ratio* sia maggiore o uguale del valore atteso, calcolato prendendo direttamente il valore della *F-distribution* per il valore di significanza α , considerando i gradi di libertà di numeratore e denominatore dell'*f-ratio*; se *p-value* è minore di α l'ipotesi nulla è falsa, quindi c'è una differenza significativa dal punto di vista statistico fra le medie dei gruppi [26].

Linear Regression La regressione lineare è una tecnica statistica utilizzata per modellare la relazione tra una variabile dipendente e una o più variabili indipendenti, in modo da definire la variabile dipendente come una combinazione lineare di alcuni valori (le variabili indipendenti), detti predittori perché una volta individuata la relazione fra tali valori e la variabile dipendente, è possibile effettuare delle predizioni sulla base dei valori osservati. La forma più comune è la regressione lineare semplice (Simple Linear Regression (SLR)), che coinvolge una sola variabile indipendente, ma esistono diverse varianti della regressione lineare che possono essere utilizzate in diverse situazioni. L'obiettivo di SLR è quello di trovare una funzione lineare che predica il valore della variabile dipendente dato un certo valore di quella indipendente (ovvero data l'ascissa, il valore dell'ordinata deve essere una predizione accurata): le predizioni sono svolte sulla base di un solo predittore [27].

Un Generalized Linear Model (GLM) è una generalizzazione che mira a rendere più flessibile la regressione lineare classica, in cui le variabili coinvolte possono seguire una distribuzione arbitraria, e viene utilizzata una *link function* che mette in relazione i predittori con la media della distribuzione della variabile dipendente; anziché far variare linearmente la variabile dipendente stessa, in questo modello è una funzione di tale variabile che varia linearmente con i predittori. La regressione lineare è un GLM in cui la distribuzione della variabile dipendente è una normale con varianza costante e la *link function*

è l'identità [11]. Il task implementato offre la possibilità di scegliere, con un opportuno parametro, se utilizzare la SLR o la Generalized Linear Regression (GLR) che utilizza un GLM.

Logistic Regression Nel caso in cui si abbia a che fare con delle variabili che possono assumere soltanto due valori (circostanza frequente nei classificatori), è possibile utilizzare un particolare tipo di regressione — la regressione logistica — che utilizza la funzione logit per associare ad un vettore in ingresso un valore di probabilità di appartenenza ad una delle due classi possibili [11, 15]. Per costruire un modello ML, durante la fase di addestramento (supervisionato) si utilizzano i dati dedicati per trovare i coefficienti della funzione logit che massimizzano la corrispondenza fra i dati e la loro classe di appartenenza, poi viene stabilito il *decision boundary* per separare le diverse classi nello spazio delle features. Una volta allenato il modello, si può utilizzare per effettuare classificazione presentando in ingresso nuovi dati: l'output del modello è la probabilità che il vettore in ingresso rappresenti un oggetto appartenente a una delle due classi. I task implementati offrono anche la possibilità di vedere i parametri necessari alla valutazione del modello (precision, recall, f-score) e l'evoluzione della precisione del modello durante la fase di addestramento.

Capitolo 3

Recupero degli algoritmi

1 Analisi

La prima fase del lavoro si è concentrata sul recupero di alcuni algoritmi sviluppati con tecnologia Spark sfruttando la libreria MLlib, originariamente implementati nell'ambito del progetto EVOTION [2]. Affinché i singoli task Spark fossero eseguibili singolarmente, dopo una prima analisi del codice già sviluppato, si è resa necessaria l'estrazione delle singole classi Java che implementano i diversi algoritmi e la contestuale creazione di un progetto autonomo per ogni algoritmo. L'autonomia dei singoli progetti è un requisito necessario per avere la possibilità di creare in maniera semplice i cosiddetti *fat jar* (o *uber jar*) — maggiori dettagli in seguito — e dal momento che le classi sono state estratte da un progetto più grande, è stato necessario risolvere le dipendenze perché ogni algoritmo potesse importare tutte le classi e librerie esterne di cui necessitava. Un'ulteriore attività svolta è stata quella di aggiornamento della versione di Spark dalla 2.2.0 alla 3.5.0, mantenendo Java 8. Numerosi algoritmi fra quelli coinvolti nel lavoro utilizzano la classe "VectorDisassembler", realizzata in Scala 2.11 per Spark 2.2.0 da un singolo sviluppatore e non più aggiornata, dunque è stata creata una *fork* della classe in modo da poter aggiornare la versione di Scala e così rendere il codice compatibile con Spark 3.5.0.

Struttura generale del codice Fra i task sviluppati, sono stati selezionati quelli che implementano gli algoritmi illustrati nel capitolo 2. In generale, i file del codice relativo a ciascun task sono inseriti all'interno di un package Java dedicato, che riporta nella denominazione il nome dell'algoritmo implementato dal rispettivo task (`it.unimi.evotion.tasks.<nome_algoritmo>`). Ciascun algoritmo è composto di base da due classi principali: il codice che implementa l'algoritmo vero e proprio è contenuto in una classe che implementa l'interfaccia

Task, definita per fare in modo che ogni algoritmo implementi i metodi `init`, `run` e `postProcessing`; l'altra classe è dedicata al *main* e il suo ruolo è sempre quello di configurare `log4j` per poi avviare l'esecuzione del task, creando un oggetto che sia istanza della classe dell'algoritmo, e poi chiamando, in ordine, i metodi precedentemente elencati. Il codice di `init` serve per configurare la `SparkSession` e riportare i parametri passati all'applicazione al momento del lancio del task. Il metodo `run` è il corpo centrale di ogni algoritmo: prevede sempre una prima sezione in cui viene caricato il dataset e i dati sono preparati all'elaborazione successiva (solitamente si opera sullo schema per rendere uniforme ogni input), poi c'è una seconda sezione in cui viene effettuato il fit del modello oppure se ne utilizza uno già allenato per fare previsioni. Con `postProcessing` ci si occupa di salvare i risultati, quindi nel caso di task in cui viene allenato un modello, i vengono salvati i parametri dello stesso, mentre nei task predittivi si salvano gli output in formato `parquet`.

Maven I progetti Java sono stati gestiti con Apache Maven, uno strumento per l'amministrazione di progetti software, quindi per risolvere le dipendenze e aggiornare la versione di Spark, l'attività svolta è stata quella di scrivere un nuovo file Project Object Model (POM) per ogni algoritmo; tale file è in formato eXtensible Markup Language (XML) e comprende sia i dettagli di configurazione del progetto, sia le informazioni necessarie a Maven per realizzare il pacchetto contenente l'applicazione Java. Il file POM contiene delle sezioni che sono dedicate alla struttura del progetto, ovvero in cui sono indicate le relazioni fra le diverse classi; una sezione dedicata alle proprietà del progetto (strettamente dipendenti dal linguaggio e dalle tecnologie utilizzate); una sezione dedicata alla fase di costruzione del pacchetto dell'applicazione Java, dove possono essere configurati vari plugin; un'ultima sezione in cui sono indicate tutte le dipendenze del progetto. All'interno di un singolo progetto possono esserci diversi file POM, ognuno che gestisce una parte del codice, a diversi livelli di dettaglio: un file più generale può indicare soltanto l'identificativo del gruppo (package) di cui fa parte il progetto, l'identificativo dell'artefatto e i diversi moduli che lo compongono; i file dei singoli moduli poi possono specificare i plugin necessari alla costruzione del file *jar*, così come le dipendenze. Alcuni algoritmi prevedono la presenza di un task Spark dedicato soltanto all'allenamento del modello e un task diverso per effettuare predizioni utilizzando il modello allenato; in questo caso è stato organizzato un unico progetto in cui i due task sono moduli di uno stesso artefatto generale. Un esempio di file POM generale è riportato nell'appendice A, mentre un esempio di un file di un singolo modulo, contenente sia i plugin sia le dipendenze, è riportato nell'appendice B. Il funzionamento di Maven si basa sull'utilizzo dei plugin, ovvero degli strumenti che combinano

più azioni in sequenza per rendere semplice la compilazione, il testing, il deployment e altre attività comuni durante lo sviluppo software. I plugin vengono configurati all'interno del file POM, nell'ambito del lavoro di questa tesi, sono stati configurati, per ciascun task, Apache Maven Assembly Plugin [3] e Log4j Transform Maven Plugin [19]. Il primo consente di costruire un archivio che contiene anche le dipendenze, i moduli, la documentazione, mentre il secondo serve per ottimizzare le chiamate di logging alle API di Log4j, infatti inserisce le chiamate di logging in posizioni statiche, in modo tale da non dover calcolare a runtime la posizione.

Uber jar Gli applicativi Java sono solitamente "confezionati" in file archivio, chiamati JAR (da Java Archive), che comprendono sia i file di diverse classi Java, sia i relativi metadati e tutte le risorse che utilizzano; queste generiche risorse possono essere sia file di testo o multimediali, sia altri file JAR. I file JAR sono un aspetto fondamentale del linguaggio Java, sia per quanto riguarda la facilità di distribuzione sia per la sicurezza, infatti è possibile inserire in un unico file, detto *uber jar* o *fat jar*, tutti i file delle classi sviluppate per l'applicativo, uniti a tutte le classi che costituiscono le dipendenze, rendendo l'archivio un file completamente autonomo, ovvero eseguibile senza necessità di importare nessuna classe esterna.

Aggiornamento della versione di Spark In particolare, l'attività di aggiornamento e riorganizzazione del codice si è svolta in più fasi in cui sono state prima risolte le dipendenze delle classi relative ai singoli algoritmi, svolgendo un test con un dataset di esempio per ciascun task, lanciando l'esecuzione direttamente dall'interno dell'ambiente di sviluppo, in seguito è stata aggiornata la versione di Spark, e sono state svolte minime modifiche al codice Java delle classi per risolvere alcuni problemi di compatibilità relativi all'aggiornamento, solitamente dovuti al fatto che nella nuova versione di Spark alcune classi sono state spostate in librerie differenti rispetto alla versione 2.2.0. Per l'aggiornamento della classe "VectorDisassembler", dopo aver effettuato la *fork* del codice, si è aggiornato il file POM, poi si è costruito il nuovo file *jar* che è stato in seguito importato da tutti i task che lo richiedevano.

Il plugin Maven Assembly è stato configurato in modo tale che venisse incluso il *Classpath* (`<addClasspath>true</addClasspath>`), è stata specificata la classe principale da eseguire una volta avviato l'archivio finale (`<mainClass>it.unimi.evotion.tasks.kmeans_model.KmeansModel</mainClass>`), è stato inserito il tipo di descrittore da utilizzare per nominare l'assembly JAR (`<descriptorRef>jar-with-dependencies</descriptorRef>`) e poi si è specificata la fase del ciclo di vita di Maven in cui eseguire l'istanza di esecuzione

(<phase>package</phase>). Una volta aggiornati i file di configurazione di tutti i progetti relativi ai singoli algoritmi, sono stati costruiti i file *uber jar*.

2 Esecuzione su un cluster Kubernetes locale

Al fine di rendere eseguibili i task Spark in un ambiente distribuito gestito con Kubernetes, è stato fatto un primo test di esecuzione in container Docker dei singoli *fat jar*, in modo tale da individuare un'immagine di partenza che soddisfasse le necessità delle singole classi, inoltre, a puro scopo dimostrativo si è anche effettuata una prova di esecuzione su un cluster Kubernetes eseguito su una sola macchina. In questa fase, sia il file archivio del task sia il dataset di lavoro sono stati aggiunti all'immagine Docker utilizzata per la costruzione dei Pod Kubernetes, tuttavia nella configurazione finale, come verrà illustrato in seguito, il file eseguibile e i dati non sono inseriti nell'immagine, ma vengono letti da un sistema di storage distribuito. Per ottenere un'immagine Docker da usare in Kubernetes, è stato usato lo strumento `docker-image-tool.sh`, messo a disposizione dalla distribuzione Spark, utile per costruire e pubblicare immagini Docker in maniera immediata.

Configurazione dell'ambiente di lavoro Il cluster locale è stato configurato su un dispositivo Apple MacBook Pro con processore Apple M1 Pro e 16 GB di memoria unificata, impostando l'applicativo Docker desktop (utilizzato anche per la gestione del cluster Kubernetes) in modo tale che potesse usare fino a 8 core di CPU e 13 GB di memoria. Da Docker desktop è stato attivato Kubernetes, in modo tale che venisse configurato un cluster con un singolo nodo (master) che contiene i Pod dedicati a: API server, controller manager, scheduler, etcd, coredns, kube-proxy (si faccia riferimento alla sezione 4 per la spiegazione delle funzioni dei singoli Pod). Una volta configurato il cluster, si è utilizzato lo script `spark-submit` per avviare l'esecuzione dei task sul cluster; con questa procedura viene impartito il comando all'API server che si occupa di creare un nuovo Pod che funge da Spark driver, a sua volta, il driver crea gli esecutori e si connette a tali nodi, per poi eseguire il codice dell'applicazione.

Implementazione Per rendere più agevole l'attività di recupero degli algoritmi, si è scelto di configurare le proprietà di Spark non attraverso le API di Java, ma con i parametri dello strumento `spark-submit`, in questo modo non è stato necessario modificare il codice e in più se ne favorisce il riuso, perché al variare dell'infrastruttura di deployment non serve apportare modifiche al codice, ma basta cambiare i parametri dello strumento di lancio. Di seguito si riportano le impostazioni utilizzate per il lancio sul cluster locale:




Figura 3.1: Funzionamento di `spark-submit`

Fonte: <https://spark.apache.org/docs/3.5.0/running-on-kubernetes.html>

1. `--master` serve per indicare l'Uniform Resource Locator (URL) dello Spark master, in particolare l'indirizzo dell'API server Kubernetes;
2. `--deploy-mode` definisce dove istanziare il nodo driver, in modalità `client` è avviato localmente e quindi si interfaccia ai nodi del cluster come nodo esterno, mentre in modalità `cluster` viene avviato direttamente sui nodi worker;
3. con `--class` si specifica la classe da eseguire all'interno dell'archivio JAR;
4. il termine indicato in `--name` è quello utilizzato da Kubernetes per nominare le risorse create per l'esecuzione dei task, come i driver e gli executors;
5. attraverso l'utilizzo di `--conf` si possono impostare diverse proprietà per la configurazione di Spark, in particolare è utile indicare il namespace in cui avviare i Pod per eseguire il task (con `spark.kubernetes.namespace`) e l'immagine con cui avviare i container (con `spark.kubernetes.container.image`), inoltre nel caso in cui sia necessaria l'autenticazione per avere il permesso di esecuzione all'interno del cluster, si indica l'account con `spark.kubernetes.authenticate.driver.serviceAccountName`.

Oltre ai parametri di configurazione, lo strumento richiede che venga indicato il JAR dell'applicazione da eseguire ed eventuali argomenti, nel caso dei task Spark coinvolti nel lavoro, è stato indicato il percorso interno all'immagine in cui è stato inserito l'archivio Java, il percorso del dataset e gli argomenti specifici per ciascun algoritmo.

3 Esecuzione su un cluster AWS EKS

Configurazione dell'ambiente di lavoro Per avvicinarsi alla configurazione di deployment finale, si è configurato un cluster Kubernetes utilizzando il servizio di cloud computing Elastic Kubernetes Service (EKS) offerto da Amazon Web Services (AWS). Sfruttando lo strumento `eksctl` si è creato un cluster di istanze di tipo Elastic Compute Cloud (EC2) *m5.xlarge* — indicate per computazione "general batch processing" — dotate di 4 CPU virtuali e 16 GiB di memoria, ed è stato esposto l'accesso remoto tramite `ssh`. All'interno del cluster si è creato un namespace dedicato all'esecuzione dei task, poi una mappatura (*iamidentitymapping*) fra uno specifico utente Kubernetes e il ruolo dedicato all'amministrazione dei container, in seguito è stato creato un ruolo IAM per l'esecuzione dei task e vi è stata associata una policy che consentisse l'accesso completo ad uno specifico bucket Amazon S3 e al servizio di monitoraggio




Figura 3.2 : Schema riassuntivo dell'infrastruttura configurata con Amazon EKS

Amazon CloudWatch, così come una policy per consentire l'amministrazione dei cluster virtuali e il lancio di "job" software (fare riferimento all'appendice C per il contenuto delle policy citate). Infine è stato creato un cluster virtuale per l'esecuzione vera e propria dei task, indicando come provider dei container il cluster fisico appena configurato.

Implementazione Con un'infrastruttura così configurata, è possibile sia eseguire i task utilizzando direttamente lo strumento **spark-submit**, come precedentemente illustrato, ma eseguendolo da un nodo appartenente al cluster, oppure si può utilizzare **EKS StartJobRun**, uno strumento pensato appositamente per l'esecuzione di Spark task in un cluster EKS, attraverso il quale viene configurato indirettamente **spark-submit**. Nell'appendice D si può vedere l'esempio di configurazione dello strumento per l'esecuzione del task che implementa l'algoritmo **kmeans**: con questa nuova configurazione, a differenza dell'esecuzione su cluster locale, l'archivio JAR e il dataset passati al tool di esecuzione, così come il percorso in cui scrivere i risultati dell'algoritmo, non sono locali all'immagine eseguita dal container nel cluster, ma sono percorsi in un bucket Amazon S3. La comunicazione fra lo Spark driver e il bucket S3 avviene attraverso **EMR File System (EMRFS)**, un'implementazione di **Hadoop Distributed File System (HDFS)** usata per leggere e scrivere file dai cluster EMR a Amazon S3 [12].

Capitolo 4

Studio e implementazione di un algoritmo di test in Tensorflow

Come illustrato nella sezione 1, la libreria Tensorflow è estremamente utilizzata in molti ambiti del machine learning, grazie alla sua semplicità d'uso e alla possibilità di ottimizzare l'esecuzione su hardware specifico. Si è studiata, dunque, l'implementazione di nuovi algoritmi sfruttando la libreria in questione, superando l'approccio con Java, pur mantenendo la possibilità di esecuzione su cluster Spark. Per farlo, è stata utilizzato un popolare modello DL che implementa una rete neurale convoluzionale per riuscire a classificare le immagini di cifre scritte a mano, di fatto riconoscendo la cifra presente nell'immagine. Il dataset [18] utilizzato per la costruzione del modello è composto da 60000 esempi dedicati al training e 10000 dedicati al testing; è presente direttamente in Tensorflow (`tf.keras.datasets.mnist`).

1 Analisi

Tensorflow ha la sua API — `tf.distribute` — che permette la distribuzione sia della computazione da parte di modelli predittivi già allenati, sia del training; è pensata per funzionare sia con il codice che utilizza API fornite da librerie di alto livello, come `Model.fit` di Keras, sia con programmi che usano Tensorflow più a basso livello, come quelli con *training step* personalizzati [10]. La grande automazione presente nei componenti della libreria Tensorflow consente di distribuire la computazione del codice applicando delle modifiche minime: occorre definire una "strategia" di distribuzione, utilizzare metodi specifici per configurare i dispositivi coinvolti in modo da comunicargli il ruolo che devono assumere nella computazione, creare il modello all'interno dello

scope della strategia appena definita. Di seguito si discute nel dettaglio ciascun passaggio.

2 Configurazione dell'ambiente di lavoro

Definizione della strategia Le strategie si differenziano sia per la tipologia di piattaforma hardware che utilizzano, sia per la modalità di parallelizzazione del training che sfruttano. Quest'ultima può essere sincrona, quindi con tutti i *workers* che lavorano contemporaneamente su diverse sezioni del dataset di input e poi effettuano una sincronizzazione ad ogni step, oppure asincrona, ovvero con un lavoro indipendente e aggiornamento asincrono delle variabili. Esistono 7 differenti strategie di distribuzione del calcolo:

1. per distribuire il training in maniera sincrona su più Graphics Processing Unit (GPU) su uno stesso dispositivo, viene utilizzata `MirroredStrategy` con cui viene creata una replica per ogni variabile del modello su ciascuna GPU. In seguito i valori sono tenuti sincronizzati e vengono aggiornati utilizzando efficienti algoritmi all-reduce che solitamente usano NVIDIA Collective Communications Library (NCCL);
2. `TPUStrategy` viene usata per effettuare il training distribuito su un cluster di Tensor Processing Units;
3. la strategia adottata in questo lavoro, `MultiWorkerMirroredStrategy`, serve per la distribuzione sincrona su diversi dispositivi. Offre la possibilità di avere più GPU su ciascun dispositivo e crea una copia di ogni variabile del modello su ciascun worker. La comunicazione fra i dispositivi può avvenire con Remote Procedure Call (RPC) (compatibile CPU e GPU) o NCCL (solo per GPU);
4. con `ParameterServerStrategy` si implementa un cluster per il training asincrono, composto da parameter server e da worker. I primi creano e conservano le variabili del modello, mentre i secondi leggono le variabili dai server per poi aggiornarle e riscriverle sui server, senza mai sincronizzarsi fra loro;
5. un'altra strategia utilizzabile su un solo dispositivo è `CentralStorageStrategy`, la quale prevede che le variabili siano soltanto sulla CPU, mentre le operazioni di aggiornamento sono svolte distribuite sulle GPU;
6. `OneDeviceStrategy` serve per memorizzare tutte le variabili ed eseguire qualsiasi funzione su uno specifico dispositivo, come una singola GPU;

7. la strategia di default, ovvero quella utilizzata nel caso in cui non venga definita una delle altre, non distribuisce il carico computazionale. Il suo scopo è soltanto quello di scrivere librerie o programmi che possano gestire ogni tipo di distribuzione e funzionino anche senza distribuire la computazione.

Configurazione Una volta definita la strategia, qualora si voglia parallelizzare la computazione su un cluster, bisogna configurare i dispositivi coinvolti in modo tale che conoscano il ruolo che devono assumere nel training o nell'utilizzo del modello predittivo. Nel caso di `TPUStrategy` si utilizzano direttamente le API Tensorflow per indicare l'indirizzo del Tensor Processing Unit (TPU) cluster resolver, connettersi e inizializzare il sistema, poi la distribuzione è gestita in maniera automatica dalla libreria. Con strategie che coinvolgono realmente più worker, come `MultiWorkerMirroredStrategy` e `ParameterServerStrategy`, si ha un controllo preciso su tutti i dispositivi del cluster. Nella variabile d'ambiente `TF_CONFIG`, scritta con formato JSON, si configura la sezione `cluster`: un dizionario contenente gli indirizzi IP e i numeri di porta di tutti i nodi del cluster, distinguendo fra worker ed eventualmente parameter server (ps) (è un'informazione uguale per tutti i nodi). Inoltre, va definita la sezione `task` che specifica il tipo e l'indice di un singolo nodo. Il dispositivo con indice pari a 0 per prassi è il nodo chief che, oltre a svolgere i compiti di un normale worker, si occupa anche di salvare i checkpoint e scrivere i *summary files* per TensorBoard. In aggiunta alla configurazione dei singoli nodi, è possibile definire la modalità di comunicazione fra dispositivi, utilizzando le API di Tensorflow e scegliendo fra `RPC` (`CommunicationImplementation.RING`) e `NCCL` (`CommunicationImplementation.NCCL`).

L'unica modifica al codice necessaria per distribuire il training, una volta definita la strategia, è quella di effettuare le chiamate alle API per costruire e compilare il modello all'interno dello scope della strategia.

3 Implementazione

La rete Convolutional Neural Network (CNN), implementata con l'API Keras, è composta da 6 layer. L'input deve avere forma 28x28, quindi le immagini sottoposte al modello devono essere quadrate e avere lato di 28 pixel. Un secondo layer (`Reshape`) si occupa di trasformare le immagini in Tensors tridimensionali. Segue un layer convoluzionale (`Conv2D`) che utilizza 32 filtri, quindi l'output ha dimensione 32, e un kernel di dimensione 3, inoltre usa "relu" (`REctified Linear Unit`) come funzione di attivazione; questo è il layer in cui viene effettivamente estratta l'informazione dall'immagine. Con il quarto layer (`Flatten`) si riducono

i Tensors tridimensionali a un vettore unidimensionale, in modo tale da poter sfruttare gli ultimi due layer che sono densamente connessi. Il penultimo layer serve a introdurre non linearità nel modello e così consentirgli di apprendere anche pattern complessi, dunque ha funzione di attivazione "relu" e output di dimensione 128. L'ultimo layer si occupa di restituire la classificazione dell'immagine in ingresso, quindi ha una funzione di attivazione lineare (di default) e 10 possibili output.

Deployment su cluster Kubernetes Per eseguire un task in maniera distribuita, è necessario implementare un cluster Kubernetes composto da tanti Pod quanti sono i nodi worker su cui si desidera distribuire il carico computazionale. Ogni singolo Pod deve avere risorse sufficienti all'allenamento del modello, quindi se si desidera utilizzare la GPU, è importante configurarla al momento della creazione del Pod. Oltre alla gestione dell'hardware, serve impostare ogni worker in modo tale che abbia accesso al codice python per il training e configurare le variabili d'ambiente per la gestione della distribuzione. Per fare in modo che ogni Pod del cluster possa raggiungere gli altri (operazione necessaria per la sincronizzazione), va creato un Kubernetes Service attraverso il quale si espone una porta del container verso la rete.

L'esecuzione svolta sul cluster locale ha coinvolto tre worker, dunque la variabile TF_CONFIG è stata configurata come segue (il valore di \$index varia fra 0 e 2).

```
TF_CONFIG='{
  "cluster": {
    "worker": [
      "worker-0:2222",
      "worker-1:2222",
      "worker-2:2222"
    ]
  },
  "task": {
    "type": "worker",
    "index": '$index'
  }
}'
```

Sia il Service sia i Pod vengono creati attraverso lo strumento kubectl, nello specifico si passa il nome del file in formato yaml al comando kubectl apply -f. Una volta create le risorse, con kubectl logs -f worker0 è possibile seguire l'avanzamento del training del modello sul worker chief; con un comando analogo è possibile visualizzare anche gli altri worker.

Il codice python del modello è stato inserito direttamente nell'immagine Docker, caricata su Docker Hub, in questo modo ogni Pod del cluster può fare il pull dell'immagine ed eseguire il codice.

Deployment su un cluster Spark esistente Qualora si voglia distribuire il training su un cluster Spark già esistente, all'interno dell'ecosistema Tensorflow è stato sviluppato un apposito componente che consente la distribuzione in maniera immediata. La funzione `MirroredStrategyRunner` all'interno del pacchetto `spark_tensorflow_distributor` può essere utilizzata in un modo del tutto simile a quello descritto nei precedenti paragrafi, infatti è costruita sulla base di `MultiWorkerMirroredStrategy`. L'utilizzo classico prevede di incapsulare il codice da eseguire su un singolo nodo all'interno di una funzione, poi si passa tale funzione a `MirroredStrategyRunner.run()`, eventualmente configurando il runner in modo tale da definire i seguenti parametri: il numero totale di GPU o CPU utilizzabili da Spark (`num_slots`), se deve essere eseguito in locale sullo Spark driver o distribuito sui worker (`local_mode`), se deve utilizzare la GPU (`use_gpu`), il nome della risorsa che Spark usa per lo scheduling della GPU (`gpu_name`), se il codice fornito per il singolo worker implementa una strategia personalizzata — ovvero una di quelle elencate precedentemente — o meno (`use_custom_strategy`).

Capitolo 5

Deployment sull'infrastruttura distribuita finale

- 1 Architettura MUSA**
- 2 Processo di deployment**

Capitolo 6

Testing e valutazione delle performance in ambiente distribuito

Per dimostrare l'effettiva distribuzione del carico computazionale sul cluster si sono svolte molteplici esecuzioni degli algoritmi ML sia sull'infrastruttura Kubernetes locale, sia su quella sul servizio di cloud computing, misurando il tempo di esecuzione ed analizzando sia i file di log sia le informazioni riguardanti lo stato del cluster nel corso dell'esecuzione dei task.

1 Spark task

Il flusso di lavoro generale atteso e che si è osservato è il seguente:

- utilizzando lo strumento EKS StartJobRun viene creato un Pod interno al cluster per lanciare il task;
- il nodo dedicato allo Spark master richiede a Kubernetes un numero di esecutori (executors) pari a quello indicato nella fase di lancio del workload, quindi viene creato un numero di Pod pari al numero di executors;
- gli indirizzi IP di ciascun executor sono registrati nel cluster e gli viene assegnato un numero identificativo;
- lo Spark master assegna l'esecuzione di un task a ogni executor, fino a quando non sono finiti tutti i task set di tutti i passi che compongono il workload;

- una volta che tutti i task sono stati completati e i nodi executors hanno riportato il risultato allo Spark driver, il lavoro è concluso, quindi gli executors vengono terminati e il Pod dedicato allo Spark driver entra nello stato "completed" (qualora il workload preveda la scrittura dei risultati in specifici file, tale azione viene fatta dal driver).

Dall'analisi dei file di log — di cui si riporta un estratto per quanto riguarda l'esecuzione di un algoritmo sul cluster AWS EKS nell'appendice E — si è trovata conferma della corretta esecuzione. Di seguito si descrive in dettaglio l'evoluzione dello stato del cluster, riportando gli indirizzi IP dei singoli Pod durante l'esecuzione del medesimo task per cui si è riportato l'estratto dei file di log.

- Appena lanciato il comando EKS StartJobRun viene creato il primo Pod che si occupa di lanciare il task vero e proprio (IP 192.168.23.130).
- Viene creato lo Spark driver (IP 192.168.36.97) che richiede a Kubernetes le risorse di cui ha bisogno.
- A questo punto vengono registrati i 4 esecutori, ovvero i nodi worker (IP 192.168.3.216, 192.168.58.9, 192.168.27.77, 192.168.47.240).
- Il driver assegna un task appartenente al primo Stage di lavoro ad ogni worker: "Starting task 0.0 in stage 0.0 (TID 0) (192.168.58.9, executor 2, partition 0, PROCESS_LOCAL, 1007791 bytes)". In questa fase tutti i Pod sono nello stato "Running".
- Quando un worker ha terminato il proprio lavoro, riporta il risultato al driver che gli assegna un nuovo set.
- Nel momento in cui tutti gli Stage sono terminati, viene stoppato lo SparkContext. Tutti i Pod dei nodi worker entrano nello stato "Terminating".
- Appena tutti i nodi worker sono stati fermati, il driver entra nello stato "Completed". Accedendo ai suoi log è possibile vedere l'esecuzione del singolo task.

2 Tensorflow task

Appena un Pod viene creato, dal momento che tramite il Kubernetes Service ha una porta esposta verso la rete, può subito connettersi agli altri nodi worker. I primi log presentati sono infatti relativi alla connessione, in particolare sul Pod con "index": 0 (chief) si legge

- 1 I tensorflow/core/distributed_runtime/rpc/grpc_server_lib.cc:449] Started server with target: grpc://worker0:1999
- 2 I tensorflow/tsl/distributed_runtime/coordination/coordination_service.cc:535] /job:worker/replica:0/task:0 has connected to coordination service. Incarnation: 15228123928711275858
- 3 I tensorflow/tsl/distributed_runtime/coordination/coordination_service_agent.cc:298] Coordination agent has successfully connected.

La prima riga indica che un server gRPC è stato avviato sul nodo worker0 sulla porta 1999. Questo server verrà utilizzato per la comunicazione tra i nodi worker nella configurazione distribuita. Il prefisso `grpc://` indica che il server utilizza il protocollo gRPC per la comunicazione. La seconda riga indica che il nodo worker0 (replica 0, task 0) si è connesso al servizio di coordinamento. Questo servizio è responsabile della gestione del processo di training distribuito, inclusa l'assegnazione dei task, la sincronizzazione e il controllo degli errori. Il valore `incarnation` è un identificatore univoco per questa connessione. L'ultima riga indica che l'agente di coordinamento, responsabile della comunicazione con il servizio di coordinamento, si è connesso correttamente al servizio. Ciò significa che il nodo worker0 è ora pronto per partecipare al processo di training distribuito. Quando tutti i nodi worker che sono indicati in `TF_CONFIG` sono pronti comincia il training del modello.

Capitolo 7

Conclusioni

Appendice A

POM generale

```
1 <project xmlns="http://maven.apache.org/POM/4.0.0" xmlns:xsi="
  http://www.w3.org/2001/XMLSchema-instance"
2     xsi:schemaLocation="http://maven.apache.org/POM/4.0.0
      https://maven.apache.org/xsd/maven-4.0.0.xsd">
3   <modelVersion>4.0.0</modelVersion>
4
5   <groupId>it.unimi.evotion.tasks</groupId>
6   <artifactId>kmeans-task</artifactId>
7   <version>1.0</version>
8   <packaging>pom</packaging>
9
10  <modules>
11    <module>kmeans</module>
12    <module>kmeans_model</module>
13    <module>kmeans_predict</module>
14  </modules>
15 </project>
```

Appendice B

POM di un singolo modulo

```
1 <?xml version="1.0" encoding="UTF-8"?>
2 <project xmlns="http://maven.apache.org/POM/4.0.0"
3     xmlns:xsi="http://www.w3.org/2001/XMLSchema-instance"
4     xsi:schemaLocation="http://maven.apache.org/POM/4.0.0 http
      ://maven.apache.org/xsd/maven-4.0.0.xsd">
5     <modelVersion>4.0.0</modelVersion>
6
7     <parent>
8         <groupId>it.unimi.evotion.tasks</groupId>
9         <artifactId>kmeans-task</artifactId>
10        <version>1.0</version>
11    </parent>
12
13    <artifactId>kmeans</artifactId>
14    <name>KMeans</name>
15    <version>1.0</version>
16
17    <properties>
18        <maven.compiler.source>1.8</maven.compiler.source>
19        <maven.compiler.target>1.8</maven.compiler.target>
20        <project.build.sourceEncoding>UTF-8</project.build.
      sourceEncoding>
21
22        <spark.version>3.5.0</spark.version>
23        <scala.version>2.12</scala.version>
24    </properties>
25
26    <build>
27        <plugins>
28            <plugin>
29                <artifactId>maven-assembly-plugin</artifactId>
30                <configuration>
31                    <archive>
```

```

32         <manifest>
33             <addClasspath>true</addClasspath>
34             <mainClass>it.unimi.evotion.tasks.kmeans.
                Kmeans</mainClass>
35         </manifest>
36     </archive>
37     <descriptorRefs>
38         <descriptorRef>jar-with-dependencies</
            descriptorRef>
39     </descriptorRefs>
40 </configuration>
41 <executions>
42     <execution>
43         <id>make-assembly</id>
44         <phase>package</phase>
45         <goals>
46             <goal>single</goal>
47         </goals>
48     </execution>
49 </executions>
50 </plugin>
51 <plugin>
52     <groupId>org.apache.logging.log4j</groupId>
53     <artifactId>log4j-transform-maven-plugin</artifactId>
54     <version>0.1.0</version>
55     <executions>
56         <execution>
57             <goals>
58                 <goal>process-classes</goal>
59             </goals>
60         </execution>
61     </executions>
62 </plugin>
63 </plugins>
64 </build>
65
66 <dependencies>
67     <dependency>
68         <groupId>org.apache.spark</groupId>
69         <artifactId>spark-core_${scala.version}</artifactId>
70         <version>${spark.version}</version>
71         <scope>provided</scope>
72     </dependency>
73     <dependency>
74         <groupId>org.apache.spark</groupId>
75         <artifactId>spark-sql_${scala.version}</artifactId>
76         <version>${spark.version}</version>
77         <scope>provided</scope>

```

```

78     </dependency>
79     <dependency>
80         <groupId>org.apache.spark</groupId>
81         <artifactId>spark-mllib_${scala.version}</artifactId>
82         <version>${spark.version}</version>
83         <scope>provided</scope>
84     </dependency>
85     <dependency>
86         <groupId>org.apache.spark</groupId>
87         <artifactId>spark-streaming_${scala.version}</
            artifactId>
88         <version>${spark.version}</version>
89         <scope>provided</scope>
90     </dependency>
91     <dependency>
92         <groupId>org.apache.logging.log4j</groupId>
93         <artifactId>log4j-api</artifactId>
94         <version>2.22.1</version>
95     </dependency>
96     <dependency>
97         <groupId>org.apache.logging.log4j</groupId>
98         <artifactId>log4j-core</artifactId>
99         <version>2.22.1</version>
100    </dependency>
101    <dependency>
102        <groupId>org.apache.spark.ml.feature</groupId>
103        <artifactId>VectorDisassembler</artifactId>
104        <version>1.0</version>
105    </dependency>
106    </dependencies>
107 </project>

```

Appendice C

IAM policies

Trust policy per la creazione del ruolo per l'esecuzione dei task, si consente al solo utente *admin* di assumere il ruolo:

```
1 {
2   "Version": "2012-10-17",
3   "Statement": [
4     {
5       "Effect": "Allow",
6       "Principal": { "AWS": "arn:aws:iam::[ID]:user/admin" },
7       "Action": "sts:AssumeRole"
8     }
9   ]
10 }
```

Nota: rispetto al file originale, l'ID del cluster è stato sostituito da [ID].

Policy che garantisce l'accesso al bucket Amazon S3 di logging (situato all'Amazon Resource Name indicato) e a CloudWatch, associata al ruolo sopracitato:

```
1 {
2   "Version": "2012-10-17",
3   "Statement": [
4     {
5       "Effect": "Allow",
6       "Action": [
7         "s3:PutObject",
8         "s3:GetObject",
9         "s3:ListBucket"
10      ],
11       "Resource": [
12         "arn:aws:s3:::logs-tasks-stentella",
13         "arn:aws:s3:::logs-tasks-stentella/*"
14      ]
15     },
```

```

16     {
17         "Effect": "Allow",
18         "Action": [
19             "logs:CreateLogStream",
20             "logs:DescribeLogGroups",
21             "logs:DescribeLogStreams"
22         ],
23         "Resource": [
24             "arn:aws:logs:*:*:*"
25         ]
26     },
27     {
28         "Effect": "Allow",
29         "Action": [
30             "logs:PutLogEvents"
31         ],
32         "Resource": [
33             "arn:aws:logs:*:*:log-group:task-group:log-stream:
              task/*"
34         ]
35     }
36 ]
37 }

```

Policy per l'amministrazione dei cluster virtuali e il lancio dei Job:

```

1  {
2      "Version": "2012-10-17",
3      "Statement": [
4          {
5              "Effect": "Allow",
6              "Action": [
7                  "iam:CreateServiceLinkedRole"
8              ],
9              "Resource": "*",
10             "Condition": {
11                 "StringLike": {
12                     "iam:AWSServiceName": "emr-containers.amazonaws.
                     com"
13                 }
14             }
15         },
16         {
17             "Effect": "Allow",
18             "Action": [
19                 "emr-containers:CreateVirtualCluster",
20                 "emr-containers:ListVirtualClusters",
21                 "emr-containers:DescribeVirtualCluster",
22                 "emr-containers>DeleteVirtualCluster"
23             ],

```

```

24         "Resource": "*"
25     },
26     {
27         "Effect": "Allow",
28         "Action": [
29             "emr-containers:StartJobRun",
30             "emr-containers:ListJobRuns",
31             "emr-containers:DescribeJobRun",
32             "emr-containers:CancelJobRun"
33         ],
34         "Resource": "*"
35     }
36 ]
37 }

```


Appendice D

Configurazione di EKS StartJobRun

```
1 {
2   "name": "kmeans",
3   "virtualClusterId": "[VIRTUAL-ID]",
4   "executionRoleArn": "arn:aws:iam::[ID]:role/EMRContainers-
    JobExecutionRole",
5   "releaseLabel": "emr-7.0.0-latest",
6   "jobDriver": {
7     "sparkSubmitJobDriver": {
8       "entryPoint": "arn:aws:s3:::test-tasks-stentella/kmeans
        -1.0-jar-with-dependencies.jar",
9       "entryPointArguments": ["s3://test-tasks-stentella/
        dataset.csv", "5",
10      "s3://test-tasks-stentella/result"],
11      "sparkSubmitParameters": "\
12      --master k8s://https://E5F648AFE82BAF20017B44F112918FBE
        .gr7.us-east-1 \
13      .eks.amazonaws.com \
14      --class it.unimi.evotion.tasks.kmeans.Kmeans \
15      --conf spark.kubernetes.container.image= \
16      755674844232.dkr.ecr.us-east-1.amazonaws.com/spark/emr
        -7.0.0:latest \
17      --conf spark.executor.instances=5 \
18      --deploy-mode cluster"
19   }
20 },
21 "configurationOverrides": {
22   "applicationConfiguration": [
23     {
24       "classification": "spark-defaults",
25       "properties": {
26         "spark.driver.memory": "2G"
```

```

27         }
28     }
29 ],
30     "monitoringConfiguration": {
31         "persistentAppUI": "ENABLED",
32         "cloudWatchMonitoringConfiguration": {
33             "logGroupName": "task-group",
34             "logStreamNamePrefix": "task"
35         },
36         "s3MonitoringConfiguration": {
37             "logUri": "s3://logs-tasks-stentella"
38         }
39     }
40 }
41 }

```

Nota: rispetto al file originale, l'ID del cluster virtuale è stato sostituito da [VIRTUAL-ID], quello del cluster è stato sostituito da [ID].

Appendice E

Estratto dai log di un esecuzione su cluster EKS

```
1 [...]
2 24/03/02 08:11:55 INFO ExecutorPodsAllocator: Going to request 4
   executors from Kubernetes for ResourceProfile Id: 0, target:
   5, known: 0, sharedSlotFromPendingPods: 2147483647.
3 [...]
4 24/03/02 08:12:02 INFO
   KubernetesClusterSchedulerBackend$KubernetesDriverEndpoint:
   Registered executor NettyRpcEndpointRef(spark-client://
   Executor) (192.168.3.216:50974) with ID 1, ResourceProfileId
   0
5 24/03/02 08:12:02 INFO BlockManagerMasterEndpoint: Registering
   block manager 192.168.3.216:46787 with 408.9 MiB RAM,
   BlockManagerId(1, 192.168.3.216, 46787, None)
6 24/03/02 08:12:02 INFO
   KubernetesClusterSchedulerBackend$KubernetesDriverEndpoint:
   Registered executor NettyRpcEndpointRef(spark-client://
   Executor) (192.168.58.9:37568) with ID 2, ResourceProfileId 0
7 24/03/02 08:12:02 INFO
   KubernetesClusterSchedulerBackend$KubernetesDriverEndpoint:
   Registered executor NettyRpcEndpointRef(spark-client://
   Executor) (192.168.47.240:41520) with ID 4, ResourceProfileId
   0
8 24/03/02 08:12:03 INFO
   KubernetesClusterSchedulerBackend$KubernetesDriverEndpoint:
   Registered executor NettyRpcEndpointRef(spark-client://
   Executor) (192.168.27.77:37000) with ID 3, ResourceProfileId
   0
9 [...]
10 24/03/02 08:12:05 INFO TaskSchedulerImpl: Adding task set 0.0
    with 20 tasks resource profile 0
11 24/03/02 08:12:05 INFO TaskSetManager: Starting task 0.0 in
```

```
stage 0.0 (TID 0) (192.168.58.9, executor 2, partition 0,
PROCESS_LOCAL, 1007791 bytes)
12 24/03/02 08:12:05 INFO TaskSetManager: Starting task 1.0 in
stage 0.0 (TID 1) (192.168.3.216, executor 1, partition 1,
PROCESS_LOCAL, 1007796 bytes)
13 24/03/02 08:12:05 INFO TaskSetManager: Starting task 2.0 in
stage 0.0 (TID 2) (192.168.27.77, executor 3, partition 2,
PROCESS_LOCAL, 1007796 bytes)
14 24/03/02 08:12:05 INFO TaskSetManager: Starting task 3.0 in
stage 0.0 (TID 3) (192.168.47.240, executor 4, partition 3,
PROCESS_LOCAL, 1007796 bytes)
15 [...]
16 24/03/02 08:12:08 INFO SparkContext: SparkContext is stopping
with exitCode 0.
17 24/03/02 08:12:08 INFO SparkUI: Stopped Spark web UI at http://
spark-0000000033fu6vq729gn-17753c8dfe38181f-driver-svc.task-
namespace.svc:4040
18 24/03/02 08:12:08 INFO KubernetesClusterSchedulerBackend:
Shutting down all executors
19 [...]
```


Glossario

algoritmi all-reduce algoritmi utilizzati nell'ambito della computazione parallela, che aggregano gli *array* (o i tensori) utilizzati da processi indipendenti in un'unica struttura dati. 24

Amazon S3 File system distribuito offerto da Amazon. III, 21, 22, 37

Apache Airflow Scheduler sviluppato da Airbnb e reso *open source*. III

Big Data Insiemi di dati ad alta dimensionalità, spesso non strutturati, prodotti in maniera continuativa da un servizio o da dispositivi IoT. III, 1, 2, 5, 6

Bigtable Sistema di archiviazione distribuito per dati strutturati. III

cluster Insieme di risorse computazionali. III, 6, 19, 21–27, 29, 45, 46

Container Unità di virtualizzazione software che contiene un software unitamente alle sue dipendenze, senza virtualizzare un intero sistema operativo. 45

data pipeline Sequenza di task che effettuano operazioni sui dati, in cui l'output di ogni task è usato come input dal successivo. 46

Docker Strumento per eseguire e amministrare i Container. III, 19, 27

file system Struttura dati utilizzata per la gestione dei dati archiviati su un supporto elettronico. III, 45

Hadoop Yarn Yet Another Resource Negotiator, è la tecnologia di gestione delle risorse e pianificazione dell'esecuzione task nel framework di elaborazione distribuita open source Hadoop. III, 2

Kubernetes Orchestratore per gestire un cluster composto da Container. III, IV, 2, 19, 21, 26, 29, 30

Luigi Scheduler sviluppato da Spotify e reso *open source*. III

MapReduce Modello di programmazione per processare in maniera semplice operazioni, svolte su grandi dataset, eseguite su cluster di grandi dimensioni. III

scheduler Strumento per la gestione di flussi di lavoro, nell'ambito specifico di questo elaborato, si intende per l'ingegnerizzazione di data pipeline. III, 45, 46

Acronimi

ANOVA ANalysis Of VAriance. 13, 14

API Application Programming Interface. IV, 5–7, 9, 19, 21, 23, 25

AWS Amazon Web Services. 21, 30

CNN Convolutional Neural Network. 25

DAG Directed Acyclic Graph. 7, 8

DL Deep Learning. IV, 1, 5, 6, 23

DoS Denial of Service. 2

EC2 Elastic Compute Cloud. 21

EKS Elastic Kubernetes Service. 21, 22, 29, 30

EMR Elastic MapReduce. III, 22

EMRFS EMR File System. 22

GLM Generalized Linear Model. 14, 15

GLR Generalized Linear Regression. 15

GMM Gaussian Mixture Model. 11

GPU Graphics Processing Unit. 24, 26, 27

HDFS Hadoop Distributed File System. 22

IA Intelligenza Artificiale. 4

IAM Identity and Access Management. VII, 21, 37

IoT Internet of Things. 1

ML Machine Learning. III, IV, 1, 2, 5, 9, 10, 15, 29

MLlib Machine Learning library. III, 1, 16

MUSA Multilayered Urban Sustainability Action. 2, 3

NCCL NVIDIA Collective Communications Library. 24, 25

POM Project Object Model. 17, 18

RDD Resilient Distributed Datasets. 7, 8

RPC Remote Procedure Call. 24, 25

SLR Simple Linear Regression. 14, 15

TPU Tensor Processing Unit. 25

URL Uniform Resource Locator. 21

XML eXtensible Markup Language. 17

Bibliografia

- [1] Hervé Abdi e Lynne J. Williams. “Principal Component Analysis”. In: *WIREs Computational Statistics* 2.4 (2010), pp. 433–459. issn: 1939-5108, 1939-0068. doi: 10.1002/wics.101.
- [2] Marco Anisetti et al. *Big Data Analytics Engine , Deliverable D5.5 to the EVOTION-727521 Project Funded by the European Union*. {}. UNIMI, Italy, 2018.
- [3] *Apache Maven Assembly Plugin – Introduction*. 2024. url: <https://maven.apache.org/plugins/maven-assembly-plugin/>.
- [4] Fay Chang et al. “Bigtable: A Distributed Storage System for Structured Data”. In: *ACM Trans. Comput. Syst.* 26.2 (2008). issn: 0734-2071. doi: 10.1145/1365815.1365816.
- [5] Li Chen et al. “Fast Kernel k -Means Clustering Using Incomplete Cholesky Factorization”. In: *Applied Mathematics and Computation* 402 (2021), p. 126037. issn: 00963003. doi: 10.1016/j.amc.2021.126037.
- [6] Xiaohui Chen e Yun Yang. “Diffusion K-means Clustering on Manifolds: Provable Exact Recovery via Semidefinite Relaxations”. In: *Applied and Computational Harmonic Analysis* 52 (2021), pp. 303–347. issn: 10635203. doi: 10.1016/j.acha.2020.03.002.
- [7] D. Coomans e D.L. Massart. “Alternative K-Nearest Neighbour Rules in Supervised Pattern Recognition”. In: *Analytica Chimica Acta* 136 (1982), pp. 15–27. issn: 00032670. doi: 10.1016/S0003-2670(01)95359-0.
- [8] T. Cover e P. Hart. “Nearest Neighbor Pattern Classification”. In: *IEEE Transactions on Information Theory* 13.1 (1967), pp. 21–27. issn: 0018-9448, 1557-9654. doi: 10.1109/TIT.1967.1053964.
- [9] Jeffrey Dean e Sanjay Ghemawat. “MapReduce: Simplified Data Processing on Large Clusters”. In: *Communications of The Acm* 51.1 (2008), pp. 107–113. issn: 0001-0782. doi: 10.1145/1327452.1327492.
- [10] *Distributed Training with TensorFlow | TensorFlow Core*. url: https://www.tensorflow.org/guide/distributed%5C_training.

- [11] Annette J. Dobson e Adrian G. Barnett. *An Introduction to Generalized Linear Models*. Fourth edition. Chapman & Hall/CRC Texts in Statistical Science Series. Boca Raton: CRC Press, Taylor & Francis Group, 2018. isbn: 978-1-138-74151-5 978-1-138-74168-3.
- [12] *EMR File System (EMRFS) - Amazon EMR*. url: <https://docs.aws.amazon.com/emr/latest/ReleaseGuide/emr-fs.html>.
- [13] Jianqing Fan, Fang Han e Han Liu. “Challenges of Big Data Analysis”. In: *National Science Review* 1.2 (2014), pp. 293–314. issn: 2053-714X, 2095-5138. doi: 10.1093/nsr/nwt032.
- [14] Sanjay Ghemawat, Howard Gobioff e Shun-Tak Leung. “The Google File System”. In: *Proceedings of the Nineteenth ACM Symposium on Operating Systems Principles*. Sosp ’03. New York, NY, USA: Association for Computing Machinery, 2003, pp. 29–43. isbn: 1-58113-757-5. doi: 10.1145/945445.945450.
- [15] David W. Hosmer, Stanley Lemeshow e Rodney X. Sturdivant. *Applied Logistic Regression*. Third edition. Wiley Series in Probability and Statistics 398. Hoboken, New Jersey: Wiley, 2013. isbn: 978-1-118-54835-6.
- [16] Abiodun M. Ikotun et al. “K-Means Clustering Algorithms: A Comprehensive Review, Variants Analysis, and Advances in the Era of Big Data”. In: *Information Sciences* 622 (2023), pp. 178–210. issn: 00200255. doi: 10.1016/j.ins.2022.11.139.
- [17] Jasmin Praful Bharadiya. “Machine Learning and AI in Business Intelligence: Trends and Opportunities”. In: *International Journal of Computer (IJC)* 48.1 (2023), pp. 123–134.
- [18] Yann LeCun, Corinna Cortes e Christopher J.C. Burges. *The MNIST Database of Handwritten Digits*. 1994.
- [19] *Log4j Transform*. 2023. url: <https://logging.apache.org/log4j/transform/latest/>.
- [20] Sergey Melnik et al. “Dremel: Interactive Analysis of Web-Scale Datasets”. In: *Proc. of the 36th Int’l Conf on Very Large Data Bases*. 2010, pp. 330–339.
- [21] Jean-Georges Perrin e Rob Thomas. *Spark in Action*. Second edition. Shelter Island, NY: Manning Publications Co, 2020. isbn: 978-1-61729-552-2.
- [22] N.A. Priyanka e Dharmender Kumar. “Decision Tree Classifier: A Detailed Survey”. In: *International Journal of Information and Decision Sciences* 12.3 (2020), p. 246. issn: 1756-7017, 1756-7025. doi: 10.1504/IJIDS.2020.108141.

- [23] Douglas Reynolds. "Gaussian Mixture Models". In: *Encyclopedia of Biometrics*. A cura di Stan Z. Li e Anil K. Jain. Boston, MA: Springer US, 2015, pp. 827–832. isbn: 978-1-4899-7487-7 978-1-4899-7488-4. doi: 10.1007/978-1-4899-7488-4_196.
- [24] Salman Salloum et al. "Big Data Analytics on Apache Spark". In: *International Journal of Data Science and Analytics* 1.3-4 (2016), pp. 145–164. issn: 2364-415X, 2364-4168. doi: 10.1007/s41060-016-0027-9.
- [25] Iqbal H. Sarker. "Machine Learning for Intelligent Data Analysis and Automation in Cybersecurity: Current and Future Prospects". In: *Annals of Data Science* 10.6 (2023), pp. 1473–1498. issn: 2198-5804, 2198-5812. doi: 10.1007/s40745-022-00444-2.
- [26] Henry Scheffé. *The Analysis of Variance*. Wiley classics library ed. A Wiley Publication in Mathematical Statistics. New York: Wiley-Interscience Publication, 1999. isbn: 978-0-471-34505-3 978-0-471-75834-1.
- [27] George A. F. Seber e Alan J. Lee. *Linear Regression Analysis*. 2nd ed. Hoboken: John Wiley & Sons, 2012. isbn: 978-1-118-27442-2.
- [28] Ketan Rajshekhar Shahapure e Charles Nicholas. "Cluster Quality Analysis Using Silhouette Score". In: *2020 IEEE 7th International Conference on Data Science and Advanced Analytics (DSAA)*. sydney, Australia: IEEE, 2020, pp. 747–748. isbn: 978-1-72818-206-3. doi: 10.1109/DSAA49011.2020.00096.
- [29] Xiaobo Shen et al. "Compressed K-Means for Large-Scale Clustering". In: *Proceedings of the AAAI Conference on Artificial Intelligence* 31.1 (2017). issn: 2374-3468, 2159-5399. doi: 10.1609/aaai.v31i1.10852.
- [30] Sidney Siegel. "Nonparametric Statistics". In: *The American Statistician* 11.3 (1957), pp. 13–19. issn: 0003-1305, 1537-2731. doi: 10.1080/00031305.1957.10501091.
- [31] Michael Steinbach, George Karypis e Vipin Kumar. "A Comparison of Document Clustering Techniques". In: (2000).
- [32] Alaa Tharwat et al. "Linear Discriminant Analysis: A Detailed Tutorial". In: *AI Communications* 30.2 (2017), pp. 169–190. issn: 18758452, 09217126. doi: 10.3233/AIC-170729.
- [33] Xue-Wen Chen e Xiaotong Lin. "Big Data Deep Learning: Challenges and Perspectives". In: *IEEE Access* 2 (2014), pp. 514–525. issn: 2169-3536. doi: 10.1109/ACCESS.2014.2325029.
- [34] Petar Zečević e Marko Bonaći. *Spark in Action*. Shelter Island: Manning, 2017. isbn: 978-1-61729-260-6.